

프로젝트학기 성과 발표회

주제 : 기존 VLA 기법의 한계 분석 및 CoT 적용 설계

팀명 안동주

작성일 2025.12.08

목차

01

Introduction

- What is VLA

02

OpenVLA

- Architecture

03

ECoT

- Embodied chain of thought

04

Experiments

- LIBERO Simulation & real world demonstration

04

Conclusion


- Comparison of OpenVLA & ECoT

Introduction

■ What is VLA(Vision Language Action)

- 단순 반복 작업만 수행하던 기존 로봇과 달리, 다양한 작업을 수행할 수 있는 VLA 로봇
- 카메라 영상과 사람의 지시문으로 로봇의 다음 행동 벡터를 예측하는 로봇 제어 모델

VLA 로봇



VLA 활용 산업



물류 로봇

화물을 구분하여 언어
지시로 이송



커피 추출 로봇

언어 지시에 맞는
레시피 제작




조립 로봇

언어 지시와 시각
정보로 더 정밀한 조립

OpenVLA^[1]

■ Architecture

- 이미지 관측과 언어 지시를 입력으로 받아 로봇 행동을 예측
- 비교 VLA 모델들(RT-2-X^[2], Octo^[3], Diffusion policy^[4])보다 매우 적은 연산량으로 더 높은 성능 달성



[1] M. J. Kim, K. Pertsch, S. Karamcheti, T. Xiao, A. Balakrishna, S. Nair, and C. Finn, "Openvla: An open-source vision-language-action model.", *arXiv preprint arXiv:2406.09246*, 2024.

[2] A. O'Neill, A. Rehman, A. Maddukuri, A. Gupta, A. Padalkar, A. Lee, and M. Chen, "Open x-embodiment: Robotic learning datasets and rt-x models: Open x-embodiment collaboration 0.", *In IEEE International Conference on Robotics and Automation, IEEE.*, 2024

[3] O. Mees, D. Ghosh, K. Pertsch, K. Black, H. R. Walke, S. Dasari, and S. Levine, "Octo: An open-source generalist robot policy." *In First Workshop on Vision-Language Models for Navigation and Manipulation at ICRA 2024.*

[4] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, and S. Song, "Diffusion policy: Visuomotor policy learning via action diffusion.", *The International Journal of Robotics Research*, 44(10-11), 2025.


[5] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov, and P. Bojanowski, "Dinov2: Learning robust visual features without supervision.", *arXiv preprint arXiv:2304.07193*, 2023.

[6] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer, "Sigmoid loss for language image pre-training.", *In Proceedings of the IEEE/CVF international conference on computer vision*, 2023.

OpenVLA

■ Architecture


- 이미지 관측과 언어 지시를 입력으로 받아 로봇 행동을 예측
- 비교 VLA 모델들(RT-2-X , Octo , Difussion policy)보다 매우 적은 연산량으로 더 높은 성능 달성



ECoT

■ Embodied Chain of Thought(ECoT)^[4]

- OpenVLA는 이미지 관찰에서 곧바로 action을 예측, 새로운 object, instruction, scene에 대한 일반화 성능 부족
- ECoT는 추론 단계를 통해 Plan, Subtask, Move를 생성 후 action 예측



Experiments

■ LIBERO simulation

- 비교를 위해 각 같은 시나리오에 대한 성능을 측정

OpenVLA

LIBERO-Goal



Task
Open the middle drawer
of the cabinet

Episodes : 50
Successes: 28 (56.0%)

LIBERO-10



Task
put both the alphabet
soup and the tomato
sauce in the basket

Episodes : 50
Successes: 31 (62.0%)

ECoT

LIBERO-Goal



Task
Open the middle drawer
of the cabinet

Episodes : 50
Successes: 36 (72.0%)

LIBERO-10



Task
put both the alphabet
soup and the tomato
sauce in the basket

Episodes : 50
Successes: 30 (60.0%)

Experiments

■ ECoT real world robot demonstration

- ECoT를 적용한 OpenVLA 실제 환경 실험 영상




Task

Put the blue cup in the white cup



Task

Put the yellow cup on the plate




Task

Put the banana on the plate

Conclusion

■ Comparison of OpenVLA and ECoT

- 새로운 데이터셋에 대한 일반화 성능 부족을 ECoT의 reasoning으로 강화
- 모든 step에서 추론을 진행하여 로봇의 다음 동작을 예측



감사합니다

주제 : 기존 VLA 기법의 한계 분석 및 CoT 적용 설계

팀 명 안동주

작성일 2025.12.08


Appendix



OpenVLA

■ Image encoder : DinoV2

- 작은 이미지에서 얻은 특징을 큰 이미지의 전역 특징과 유사하도록 학습
- Model의 output을 통해 다양한 작업에 활용 가능




OpenVLA


■ Image encoder : SigLIP

- 학습 과정에서 본 적 없는 이미지를 성공적으로 예측 가능
- 이미지와 문장을 함께 학습해서 문맥을 효과적으로 파악 가능

Standard Classification



SigLIP Classification



OpenVLA

■ Tokenizer & Predict action

- 각 단어마다 지정된 ID로 변환하여 모델에 입력
- Output 확률 분포 vector에서 가장 점수가 높은 Token으로 예측

